



CEEC 中国能建
ENERGY CHINA

CPECC 中电工程

CEEC
中国能建
ENERGY CHINA

CPECC
中电工程

中国电力工程顾问集团有限公司
CHINA POWER ENGINEERING CONSULTING GROUP CO.,LTD.

典型AI算力任务时序功率曲线预测模型研究

项目编号：DG2-X01-2025

项目负责人：傅旭

牵头单位：中和院

项目参加单位：浙江院、安徽院、天津院、东北院

2026年8月25日

目录

CONTENTS

PART 1

研究现状

PART 2

研究思路和方法

PART 3


当前存在的问题

PART 4

下一步工作安排

◆ 不同模态AI任务之间能耗差异显著

Luccioni et al.(2024)



5种模态模型推理碳排放差异，其中横轴表示各模型的参数数量，纵轴表示每进行1000次推理所对应的平均碳排放量（两条坐标轴均采用对数刻度）。

一般情况下，在模型参数规模接近时：文本类任务能耗 < 图片类任务；分类任务 < 生成类任务。

◆ 文本类AI任务—LLM模型的推理能耗影响因素研究

Caravaca et al.(2025)研究了21种GPU配置和155种模型架构（从小型开源模型到前沿系统），共完成超过32,500次测量。通过vLLM推理引擎，量化了指令级层面的能耗，并揭示了架构设计与运行参数如何影响能耗需求。并在此基础上，开发出一种能够估算未见架构及硬件环境下的推理能耗的预测模型。

➤ 实验设置

推理引擎：vLLM；

能耗测量：Codecarbon（基于 NVIDIA 管理库（NVML））测量GPU能耗

LLM模型：基础模型55种+本研究修改模型架构构建模型变体，共155种模型。

GPU类型：21种不同的GPU配置，包括 NVIDIA V100、T4、L4、A100和H100。

实验规模：百万prompt级别，共计32500次推理实验。

探究变量：内容长度、批量大小、架构细节、量化模型、硬件差异。

收集信息：（1）模型层面：模型规模（参数数量）、嵌入层、自注意力机制、FFN 参数、层数、模型维度、注意力头数量、自注意力的实现方式，以及模型是否采用专家混合模型（MoE）。（2）GPU层面：GPU内存容量、TFLOPS（取决于模型精度）、CUDA 核心数、GPU带宽、TDP；其他关键参数：如模型加载后剩余可用内存空间，以及提示词在键值缓存中的占用空间。

◆ 文本类AI任务—LLM模型的推理能耗影响因素研究

➤ 研究结果

Caravaca et al.(2025)





Fig. 2. Energy consumption with long context. Measurements done with 2 NVIDIA L4 GPUs with the Phi-3 mini 128k context size.

➤ 输入token越多，能耗越高；输出token越多，能耗越高。输出token数量对能耗影响大于输入token数量。

➤ 并发处理有助于降低单次推理能耗，长上下文KV缓存容量是瓶颈，上下文长度会影响请求并发数量，上下文长度变长，并发处理优势逐渐消失。

◆ 文本类AI任务—LLM模型的推理能耗影响因素研究

➤ 研究结果




Fig. 3. **Energy consumption by number of prompts.** The plot shows how GPU energy per prompt decreases with increasing batch size. Each prompt contains 300 T_{input} and 300 T_{out} .

- batch size越大，基本上平均每一个prompt推理的能耗越低，但是随着batch size增大，KV cache和通信带宽的限制也越来越明显，提高batch size产生的能耗降低边际效应递减。

Caravaca et al.(2025)




Fig. 4. **Model Parameters against energy consumed.** This plot shows the energy consumed using LLMs by prompt using prompts with 500 input and output tokens.

- 参数总量只能粗略描述模型大小，不能完全解释推理能耗。参数位于什么结构、推理时是否被激活、产生多少计算和KV cache，往往更加重要。
- 粗略的趋势是参数量多的模型，一般能耗也更高。

◆ 文本类AI任务—LLM模型的推理能耗影响因素研究

Caravaca et al.(2025)

➤ 研究结果




Fig. 7. Energy consumption by modifying attributes of the Self-Attention mechanism of Gemma 7B model. Left side chart shows the variation of Attention heads (original model has 16). Right side shows the variation of KV Heads, showing MQA, GQA and MHA energy usage.

- 一般随着attention head增大，能耗增加；KV数增加能耗也增加；input/output的token越多，长序列对KV cache影响越大，能耗变化越明显。






Fig. 8. Quantization Experiment

- 降低数据精度可以降低对内存的需求，尤其在内存紧张的情况下，量化技术带来的能耗降低效果显著；内存不紧张时，量化技术带来的效果不明显。但同时量化技术会降低模型精度。


◆ 文本类AI任务—LLM模型的推理能耗影响因素研究

➤ 研究结果

Caravaca et al.(2025)



➤ GPU架构（内存容量、内存带宽、热设计功率（TDP）、吞吐TFLOPS）和数量对不同模型、同一模型不同参数能耗效果不同。




➤ 对较小模型，启用CUDA Graph通常有明显能耗收益；对Gemma-7B等较大模型，收益开始减弱；对更大的模型，两种执行方式的能耗越来越接近；但如果显存非常充足，大模型仍然可能从CUDA Graph中受益。

总的来说，单纯使用模型参数量或TDP不足以预测AI任务功率，需要构建任务特征—运行架构—硬件特征的多维映射。


◆ 文本类与图类AI任务—LLM模型、diffison模型的推理能耗影响因素研究

Chung et al.(2025)推出了ML.ENERGY基准测试套件(用于测量真实服务环境中推理能耗), 研究展示了该基准测试涵盖6种不同任务下40种常用模型架构的请求级能耗数据; 分析了机器学习设计决策对能耗的影响案例。

➤ 测量结果



(a) NVIDIA A100



(b) NVIDIA H100


各类生成式AI模型的每请求能耗情况。黑色与橙色分别代表文本处理与视觉处理模式。实心柱状图表示实际能耗值, 阴影柱状图则基于GPU的 TDP 进行估算 (Y轴采用对数刻度)。

- diffusion模型请求级别能耗通常大于同参数量级别的LLM模型。(diffusion model普遍能耗高、且并行数量低导致摊销效果比较小)
- 相似大小的模型一个request的能耗也有差异, 这是由模型对请求的输出的长度不同导致的。这一现象尤其在reasoning model中显著, 因为输出长度更长, 并且由于输出长度长, batch size没法很大, 故摊销效应也比较低。
- 存在参数更多的模型反而能耗低, 这是由于内存的影响。例如Phi-3 Mini (3.8B) 和 Small (7B), Small采用GQA, Mini采用MHA, 导致Mini中KV cache比较大, 内存成为瓶颈, batch size不大, 摊销效应低。


◆ 文本类与图类AI任务—LLM模型、diffison模型的推理能耗影响因素研究

➤ 测量结果

Chung et al.(2025)




(a) Energy vs. Batch Size




(b) Batch Size vs. Max Batch Size config

Figure 4: Phi-3 Mini and Small [26] benchmarked with the chat task on one NVIDIA A100 GPU.



(a) Llama 3.1 70B [73]



(b) Stable Diffusion 3 Medium [25]

Figure 5: Power consumption of Llama 3.1 70B and Stable Diffusion 3 Medium models.

➤ 有可能参数更多的模型反而能耗低，主要是内存瓶颈带来影响。例如Phi-3 Mini (3.8B) 和 Small (7B)，Small采用GQA，Mini采用MHA，导致Mini中KV cache比较大，内存成为瓶颈，batch size不大，摊销效应低。

➤ 大语言模型的功率远低于GPU的最大功率上限，而扩散模型的功率则接近最大值（大语言模型的解码过程具有较低的运算强度特征，GPU的计算吞吐量受显存带宽限制，计算单元利用率低下，降低整体功率）。

◆ 文本类与图类AI任务—LLM模型、CNN模型的训练能耗预测模型研究

Newkirk et al.(2025)通过整合布鲁克海文国家实验室在8个H100系统上进行AI训练时获得的实测数据与开源基准测试数据，建立了将计算强度与节点级能耗相关联的统计模型，并测量了制造商标称热设计功率（TDP）与AI训练实际功率之间的差异（即便是计算密集型工作负载，其运行功率也仅达到10.2 kW TDP 额定值的76%）。并针对浮点运算特性校准专用模型，在预测能耗方面平均绝对误差仅为11.4%，显著优于基于 TDP 的方法（误差范围为27%至37%）。

➤ 模型设计

$$Y = \sum_{i \in C} P_i, \quad C = \{G, U, D, I, F\}, \quad P_i = \phi_i(x).$$

$$P_{\text{comp}} = \lim_{x \rightarrow \infty} \sum_{i \in C} \phi_i(x) = \sum_{i \in C} P_{i, \text{max}}.$$

Y为服务器总功率；GPU加速器(G)、监控逻辑单元(U)、内存与存储系统(D)、互连模块(I)以及散热风扇(F)；x为操作次数；Pcomp为最大功率上限，故 $Y \leq P_{\text{comp}}$ ；

候选模型函数形式： $Y = P_{\text{idle}} + P_{\text{comp}} \frac{x}{\alpha + x}$ ， $Y = P_{\text{idle}} + P_{\text{comp}} \frac{e^{(x-x_0)/k}}{1 + e^{(x-x_0)/k}}$ (sigmoid函数形式)

输入变量x：选择浮点运算次数（FLOPS）作为衡量计算强度的指标。expected required FLOPS是训练特定模型所需的预期浮点运算次数(M)：该数值反映了训练过程中所需算术运算量。对于Transformer架构模型，采用 Narayanan 等人（2021）的公式（10）。

$$M_{\text{LLM}} = 96 \times B_{\text{global}} \times S \times L \times H^2 \times \left(1 + \frac{S}{6H} + \frac{V}{16LH}\right) \quad (10) \quad B_{\text{global}} = B_{\text{mini}} \times \frac{\text{Total GPUs}}{\text{TP} \times \text{CP} \times \text{PP}}$$

B_{global} 为全局批量大小，S为序列长度，L为层数，H为隐藏层维度，V为词表大小。系数96表示在前向和反向传播过程中每个非嵌入参数均涉及六次运算（ $2 \times 3 \times 16$ ）； B_{mini} 表示小批量大小，TP、CP和PP分别代表张量、上下文和并行处理（Parallel Processing）

◆ 文本类与图类AI任务—LLM模型、CNN模型的训练能耗预测模型研究

➤ 数据集情况:

Newkirk et al.(2025)

workload	arch.	param.	batch(global)	nodes	flops	flops/node	$p_{avg}(kw)$	$P_{max}(Kw)$	sd(kw)	duration(hours)	it energy(kwh)
smc-gpt3-175 b[64]	DNN	175B	2048	64	6.01×10^{18}	9.40×10^{16}	7.67	8.45	0.73	0.95	464.94
smc-llama-70 b[64]	DNN	70B	64	64	1.47×10^{17}	2.29×10^{15}	5.91	8.76	1.52	0.03	12.10
smc-llama-70 b [8]	DNN	70B	8	8	1.83×10^{16}	2.29×10^{15}	7.73	8.73	1.11†	0.09	5.43
smc-llama-70 b [1]	DNN	70B	8	1	1.83×10^{16}	1.83×10^{16}	6.78	7.32	1.05	0.5	3.39
bnl-llama-13 b [1]	DNN	13B	8	1	6.03×10^{18}	6.03×10^{18}	7.79	8.42	0.61	8	62.36
smc-resnet 1 [8]	CNN	26 M	3200	8	3.46×10^{13}	4.32×10^{12}	6.36	7.89	1.66	0.07	3.75
smc-resnet 2 [1]	CNN	26 M	3200	1	3.46×10^{13}	3.46×10^{13}	6.76	6.88	0.29	0.22	1.51
bnl-resnet 1 [1]	CNN	60 M	512	1	3.54×10^{11}	3.54×10^{11}	4.6	5.02	0.34	26.8	123.41
bnl—resnet 2 [1]	CNN	60 M	4096	1	2.83×10^{12}	2.83×10^{12}	5.76	6.48	0.11	5.25	30.15

➤ 研究结果

Table 3. Robust weighted regression estimates of active power coefficients estimates, statistical significance, and prediction accuracy for three model specifications. The Asymptotic model uses a single power saturation parameter, while the Architecture-Specific model employs separate parameters for LLM and CNN workloads. The Sigmoid model implements a different functional form with transition steepness parameter k. All models were validated against four out-of-sample workloads. All significance and standard errors are the cluster-robust values. Stars denote significance codes, MAPE values show in-sample error followed by out-of-sample error in parentheses and demarcated by a dagger. Note the parameter k is dimensionless and is displayed with the others for convenience.

Model	COEF.	Estimate (kW)	STD. Error (kW)	T-Value	P-Value	Energy Mape (%)
Asymptotic $\hat{Y} = P_{idle} + \beta_{comp} \frac{\log(x)}{\alpha + \log(x)}$	β_{comp}	6.65	(.35)	19.04	< 0.001***	11.8(7.6 [†])
Architecture-fixed effect $\hat{Y} = P_{idle} + \beta_{arch} \frac{\log(x)}{\alpha + \log(x)}$ where β_{arch} depends on model architecture	β_{comp}^{LLM}	6.89	(.50)	13.65	< 0.001***	11.1(5.4 [†])
	β_{comp}^{CNN}	6.28	(.32)	19.46	< 0.001***	
Sigmoid $Y = P_{idle} + \beta_{comp} \frac{e^{(x-x_0)/k}}{1+e^{(x-x_0)/k}}$	β_{comp} k	6.94 0.19	(1.33) (.16)	5.23 1.19	< 0.001*** .235	9.3(5.5 [†])

渐近模型采用单一功率饱和参数；架构特定模型则为LLM和CNN工作负载分别设置独立参数；Sigmoid模型采用具有过渡陡度参数k的不同函数形式。所有模型均在四个样本外工作负载上进行了验证。星号代表显著性判定代码，MAPE 值以样本内误差值开头，括号内为样本外误差值，并用匕首符号表示。需注意参数k无量纲，为便于表述与其他参数一同呈现。


基于研究结果Architecture-specific model表现最优。

◆ 文本类与图类AI任务—LLM模型、CNN模型的训练能耗预测模型研究

➤ 研究结果

模型预测功率的表现：

Newkirk et al.(2025)




将工作负载能耗估算值与实测数据（100%）进行标准化比较。虚线柱状图展示了基于芯片 TDP 值的估算值（下限）与基于节点 TDP 值的估算值（上限）之间的范围；实心点表示实测能耗值（颜色根据数据来源区分），黑色叉标记表示模型预测值。训练样本工作负载位于图表左侧，非训练样本工作负载位于右侧。所提出的架构固定效应模型能耗估算结果（样本内平均绝对百分比误差为11.05%，非样本外为5.39%）在所有评估工作负载中均优于两种基于 TDP 值的方法（芯片 TDP 值 MAPE 误差为21.82%，节点 TDP 值 MAPE 误差为42.41%）。非样本外性能差异很可能源于计算饱和度较高的工作负载。


◆ LLM模型、diffusion模型时序功率特征

➤ 基于transformer架构的LLM模型在训练、微调、离线推理和在线推理场景下功率特征形态差异明显。


• 训练、微调功率曲线



在 DGX -H100 机架上进行的大规模训练任务功率



Llama-2 70B 微调功率（所有 CPU 、 GPU 设备总功率）




在 AMD GPU 7900 XTX 上微调的 GPT2-medium 模型的功率

训练与微调功率均存在典型的方波特征，且不同阶段功率波动特点不同。


◆ LLM模型、diffusion模型时序功率特征

➤ 基于transformer架构的LLM模型在训练、微调、离线推理和在线推理场景下功率曲线特征形态差异明显。

• 离线推理、在线推理功率曲线



Llama-3 70B 离线推理功率曲线图（随提示词数量与输出令牌长度变化而变化）。中位数：线条，10%–90 %位数区间：阴影。




Llama-3 70B 在线推理基准测试的功率曲线（数据集、请求率，输出 tokens 长度）；批处理大小1000 提示词。中位数：线条，10%–90 %位数区间：阴影。

推理阶段功率波动弱于训练及微调阶段，随着批处理规模的增大功率强度升高；在线推理功率强度与需求到达率密切相关


◆ LLM模型、diffusion模型时序功率特征

➤ 扩散模型与LLM模型功率曲线特征形态差异明显。

Chung et al.(2025)



(a) Llama 3.1 8B



(b) Stable Video Diffusion XT

- 大语言模型推理的prefill阶段功率明显高于decode阶段。
- diffusion模型的denosing阶段功率最高，明显高于encode和decode阶段。
- 震荡可能是由于需要CPU指令，因此GPU活动烈度降低。

Figure 12: GPU power draw breakdown over time on one NVIDIA H100 GPU. “Entire GPU” and “Only VRAM” (memory) were measured, and the two were subtracted to derive “Entire GPU excluding VRAM.”

◆ 总结

- 总的来说，单纯使用模型参数量或TDP不足以预测AI任务功率，需要构建任务特征—运行架构—硬件特征的多维映射。以下因素均对AI任务能耗产生影响，例如**AI任务模态**、**预训练/微调/推理阶段**、**训练模型阶段****模型侧**：例如总计算量、并行策略（PP，DP，TP）、模型架构因素（MOE，模型层数、hidden size、intermediate size、embedding parameter、KV头数、注意力头、local batch size，使用的GPU卡数，模型总参数，训练数据集的Seq Len，是否采用CUDA graph，量化精度等影响因素；**硬件侧**：GPU的算力、内存、通信带宽、TDP等因素。**模型推理阶段影响因素模型侧**：batch size大小、input token、output token、在线推理的需求大大率和用户可接受延迟时间、以及上述训练阶段的大部分模型架构因素；**硬件侧**：同训练阶段。

➤ 当前研究存在的问题

- 当前大部分研究主要关注影响AI模型训练、微调、推理的能耗影响因素研究，而对能耗预测的研究较少。
- 部分研究注意到不同类型AI任务功率曲线具有不同的特征，但没有系统研究利用AI任务的阶段结构进行进一步特征分析与时序功率曲线预测研究。
- 当前研究表明GPU硬件架构对AI任务能耗影响不可忽视，但目前系统性研究AI任务+国产GPU能耗比较缺乏。

目录

CONTENTS

PART 1

研究现状

PART 2

研究思路和方法

PART 3

当前存在的问题

PART 4

下一步工作安排

◆ 模型设计

- 研究目标：基于AI任务特征→时序功率曲线和总能耗的映射模型
 - AI任务研究范围：LLM模型训练/推理、diffusion模型训练/推理
 - 能耗范围：GPU板、CPU、DRAM能耗（系统内存）（节点间通信能耗暂不进行精细建模研究）
 - AI模型来源：HuggingFace Transformers（支持调用多种预训练 LLMs 的 Python 库）、diffusion开源模型
 - 模型数据集来源：开源数据集和实验测量

(1) 开源数据集

数据集名称	来源文献	数据集链接
bnl_h100_single_node	Empirical Measurements of AI Training Power Demand on a GPU-Accelerated Node	https://kilthub.cmu.edu/articles/dataset/AI_Training_Node_Level_Power_Draw/29067572
power_hungry_processing	Power Hungry Processing: Watts Driving the Cost of AI Deployment?	https://github.com/sashavor/co2_inference
ml_energy	The ML.ENERGY Benchmark: Toward Automated Inference Energy Measurement and Optimization	https://huggingface.co/datasets/ml-energy/benchmark-v3
charllm_ppt	Characterizing the Efficiency of Distributed Training: A Power, Performance, and Thermal Perspective	https://github.com/scai-tech/CharLLM-PPT
mit_supercloud	The MIT Supercloud Dataset.	https://dcc.mit.edu/data/
vercellino_genai_power_profiles	Measurement of Generative AI Workload Power Profiles for Whole-Facility Data Center Infrastructure Planning	https://data.nlr.gov/submissions/312

未找到数据链接：MLPerf power: Benchmarking the energy efficiency of machine learning systems from μwatts to mwatts for sustainable AI; From Prompts to Power: Measuring the Energy Footprint of LLM Inference; Watt Counts: A Comprehensive Dataset of Energy Measurements for LLM Inference.

◆ 模型设计

➤ 研究目标：基于AI任务特征→时序功率曲线和总能耗的映射模型

(2) 实验测量

- 可采用的方法（初步调研结果）：
 - （1）采用文献中的ML.ENERGY套件进行功率测量，该套件可以根据设定的模型、数据集、模型策略（例如PP,TP,DP等）设定好环境并进行运行和GPU功率测量。
 - （2）根据文献调研结果基于软件的GPU功率测量比较准确，原理上是基于NVIDIA管理库（NVML）进行功率测量，例如Codecarbon、EnergyMeter、WattAMeter。
 - （3）CPU测量可以基于Intel Running Average Power Limit (RAPL)，例如WattAMeter。
 - （4）DRAM测量仍可以基于Intel Running Average Power Limit (RAPL)，例如EnergyMeter
 - （5）实验测量原则可以参考MLPerf建立的框架。

➤ 建模思路1：数据驱动模型构建

- （1）总能量与曲线模板：根据任务特征和配置预测总能耗、持续时间及归一化形状模板，再还原功率曲线。
- （2）直接数据驱动模型：使用任务、配置和运行状态直接预测功率，可采用传统时序模型、深度学习时序模型等。
- （3）阶段化灰箱模型：识别或预测阶段，再分别为每个阶段建立任务特征→归一化形状特征预测和持续时间预测模型，在独立建立灰箱模型实现任务特征和配置预测总能耗，结合各阶段归一化形状特征，获得完整功率曲线预测。

◆ 模型设计

➤ 建模思路2（建议暂不选择该条路径）：物理驱动模型构建

- **大致思路：**利用AI算子中规则化的tiling和pipelining结构，快速重建GPU的粗粒度执行过程，以执行过程推导模块利用率，再用利用率驱动功率模型；分析模型负责可解释性和迁移性，数据拟合负责现实准确性。该模型基于AI任务获得算子序列、各算子的张量形状以及GPU配置，然后模型将预测算子的执行方式、硬件模块利用率、执行时间和GPU平均功率和执行时间（即总能耗也由此获得）。
- **优点：**在于采用机理模型与数据驱动修正相结合建模思路，将AI任务与GPU功率建立可解释联系，能够区分SM负载分布、不同存储层级访问以及Tensor Core等模块活动的影响，具有较好的可解释性、计算效率和一定的硬件迁移能力。
- **缺点：**于该方法对输入和离线校准的要求较高，需要预先获得AI任务的算子序列、张量形状、数据精度、GPU架构及频率电压等信息，并依赖实测kernel数据库拟合修正系数，因此并非真正的零测量模型；其结果还会受到CUDA、PyTorch、cuBLAS及算子融合策略等软件栈变化的影响。现有方法主要适用于规则、顺序执行的单GPU kernel，难以处理非结构化稀疏、动态控制流、多任务并发、多GPU通信及计算—通信重叠。其跨GPU迁移依赖不同架构具有相近单位计算和访存能效的假设，对硬件代际和显存技术变化较大的平台仍需重新校准。**该方法总体技术难度、使用成本和使用难度都比较高。**

目录

CONTENTS

PART 1

研究现状

PART 2

研究思路和方法

PART 3

当前存在的问题

PART 4

下一步工作安排

- **开源数据集方面：**开源数据集提供的任务标签可能不足，需进一步筛选可用的数据集。
- **硬件资源方面：**目前硬件资源支持尚未落实，有的开源数据集体量比较大，难以下载本地处理。另外实验开展也需要硬件资源支持。
- **实验方面：**预训练实验难以开展，微调训练实验和模型推理实验可以考虑开展。
- **研究边界方面：**研究边界和任务分类需进一步收敛。另外需明确时序曲线建模的时间分辨率（秒级？）
- **建模方面：**当前的输入特征较多，需要进一步研究讨论确定输入特征的设计。

目录

CONTENTS

PART 1

研究现状

PART 2

研究思路和方法

PART 3

当前存在的问题

PART 4

下一步工作安排

- 需要进行的工作：研究边界确定、开源数据集进一步筛选、技术路线确定、课题所需要的硬件条件协调、具体的实验方案完整设计等。

—— 谢 谢! ——
THANKS!



后续报道、交流、资料分享等
请关注公众号：中电工程、中电碳中和发展研究院